扬子鳄肠道病毒组：流程测试报告

六样本公共数据的技术验证与 pilot 设计依据 | v1.0 | 2026-11-08 | PRJNA539906

摘要

用 6 个公开的扬子鳄粪便 shotgun 宏基因组（3 冬 / 3 夏，562 Mb 组装序列）跑通"去宿主 → 组装 → 病毒识别 → 完整性 → vOTU 聚类 → 丰度定量 → 群落比较 → 宿主预测"全流程。结果：**12,016 条病毒 contig（51.9 Mb）、9,980 个 vOTU、202 条中高质量病毒基因组**（最长 201.8 kb，含两条完整环状）；read 层面"病毒样" 0.69% 经四项验证确认为**数据库覆盖率上限**，真实病毒特异信号为 0.10%；群落随宿主生理状态变化、与日历季节不一致（个体 F5 为反例）。

判断：病毒层技术可行、产出量足够独立成题、且无法被 16S 替代；但个体差异远大于组间差异，pilot 必须用同一个体纵向配对设计。

一、先回答三个技术问题

细菌层已有布局（USTC 项目、校内 16S 工作），病毒/噬菌体层无立项无论文。"空白"本身不构成理由，提出 pilot 前必须先回答：短读长能否拼出**足够多、可定量**的病毒基因组？"病毒信号"会不会只是保守域假阳性？跨样本比较该用什么口径，才不把方法学差异读成生物学差异？

用公共数据把流程完整跑一遍，以下是用真实计算得到的答案。

二、完成的工作

fastp 0.23.4 质控（Q30 升至 88.2–95.9%，保留率 91.5–98.8%）→ bowtie2 去宿主（残留 0.07–2.51%）→ MEGAHIT 1.2.9 组装（**164,923 contigs / 562 Mb**）→ geNomad 1.13.0 识别（**12,016 条病毒 contig，占 7.3%，51.9 Mb**）→ CheckV 1.1.1 完整性（**202 条中高质量：Complete 29 / High 48 / Medium 125**）→ CD-HIT-EST 95% ANI 聚类（**9,980 vOTU**，归并率仅 16.9%）→ bowtie2 回贴统一参考得 RPKM 全矩阵 → iPHoP 1.2.0 全库做宿主预测（blastn 对 307 Gb 宿主基因组 + CRISPR spacer + WIsH k-mer + VHM + PHP + RaFAH 六路证据融合）。

单样本 50–70 分钟，8 核 / 125 GB 机器即可，无特殊硬件需求。

三、四个结果

结果 1 | read 层面的 0.69% 是上限，真实信号 0.10%

六个样本"病毒样 reads"挤在 0.675–0.702%，方差小得反常。四项验证确认这是技术平台，不是生物学真实值（图 M1）：

- **阈值阶梯**：一致性 ≥40% 时 0.693%，≥50% 降至 0.370%，**≥60% 直接归零**——数据中不存在与已知病毒近缘的株。
- **双零假设**：重排 reads（破坏顺序、保留组成）命中 **0**；反转蛋白库（破坏结构域、保留氨基酸组成）命中 **0**。信号依赖真实序列顺序。
- **功能构成**：47.4% 命中是代谢/管家酶（巨型病毒从宿主"偷"来的基因），**结构蛋白仅 1.3%**。
- **双端一致性**：两端同物种比例 36–43%，独立随机期望 1.6–2.4%，富集 **16–25 倍**。

三口径：病毒样 0.693%（上限） / 病毒特异 0.103%（主指标） / 仅结构蛋白 0.0089%。

含义：read 层面只能做"有没有"筛查，给不出物种与基因组。**必须组装**——这排除了"浅测序 + 比对"的省钱方案。

结果 2 | 组装能产出可用的基因组资源

202 条中高质量基因组，长度中位 **32.5 kb**，最长 201.8 kb，含三条 >190 kb 巨噬菌体（两条 100% 完整）。分类高度一致：**95.8–97.8% 为有尾噬菌体纲 Caudoviricetes**，无真核 DNA 病毒优势类群——符合粪便病毒组预期，也说明不是宿主污染（图 M3）。

产量与病毒丰度同步：S2/S3 贡献 130 条（64%），W2 仅 10 条，**平均约 34 条/样本**。按同等深度外推，30 样本 pilot 预期 **800–1,200 条**，足以支撑噬菌体–宿主网络与毒力/耐药基因携带分析。

宿主定位是最有用的一块：202 条里 **83 条（41.1%）** 定到宿主属（置信度 ≥90），**前噬菌体更高——21/33（64%）**，因其本就嵌在宿主基因组里。其中 **11 条的宿主属含已知鳄类条件致病菌**（*Edwardsiella* 5、*Aeromonas* 4、*Citrobacter* 2、*Yersinia* 2），另 7 条落在 *Bacteroides*。

注意：CheckV 完整性判定依赖长度（Complete 中位 53.9 kb vs Medium 25.2 kb）。**202 条是下限，不是真实总数。**

结果 3 ｜ 群落跟随宿主生理状态，而非日历季节

六样本在碱基组成上分成两类（图 M2A）：S2/S3 读段 GC **39.0 / 39.7%**，W1/W2/W3 为 **50.3 / 45.9 / 45.3%**。GC 越低、病毒越丰富（12.8–15.2% vs 2.1–3.9%）。

统一参考做丰度加权后，病毒组结构与分型完全吻合：**同季节 Bray-Curtis 0.660，跨季节 0.912**；S2–S3 仅 0.151，其余配对 0.71–0.97（差 5–6 倍）。加权 Jaccard 同向（0.186 vs 0.031）。

关键反例 S1（个体 F5）：7 月采样，但 GC 46.6%、病毒 reads 仅 2.14%，两项都落在冬季区间；与冬季样本的病毒距离（0.82–0.89）明显小于夏季（0.94–0.95）。**独立数据类型验证**：下载同批 16S，15-mer 谱余弦相似度显示 **A.F5 与冬季组 0.801、与夏季组 0.415**；A.F3 与 A.F4 高达 **0.995**（几乎同一群落，也解释了二者病毒组的高度相似）。

> 含义：日历季节只是生理状态的粗糙代理。原 study 按采样季节分组存在个体误分类。**pilot 必须记录摄食/禁食状态，并以个体为单位纵向比较。**

结果 4 ｜ 细菌有核心，病毒没有

9,980 个 vOTU 中 **84.5%（8,430 个）只属于单样本，六样本共有的为 0**；而原 study 在细菌层面报告了稳定核心菌群。同一批个体、同一份数据，细菌有共有成员、病毒几乎没有。

但此结论依赖口径：丰度加权后六样本共有 vOTU 从 0 变为 5，冬季核心 vOTU 达 87 个。**引用时必须标明口径。**

> 含义：病毒组个体特异性远高于细菌组。这是科学卖点（更适合个体标识与个体级扰动追踪），也是**设计警告**——横断面"病 vs 健康"会被个体背景淹没。

四、对 pilot 的四条直接含义

#	结论	设计含义
1	病毒信息完全不在 16S 里	**必须 shotgun**：本次全部结果没有一条能从 16S 得到
2	个体差异 ≫ 组间差异（病毒占比 1.41–13.34%，近 10 倍；84.5% vOTU 单样本特有）	**必须同一个体纵向配对**，3–4 个时间点。原 study 因季节与个体完全混淆，最终答不了自己提出的问题
3	各自组装再比 contig 有无会系统性低估共享（同季节 0.04 → 0.19；共有 vOTU 0 → 5）	**流程必须统一参考 + 丰度加权**；测序深度不能压到"够拼就行"
4	约 34 条基因组/样本	30 样本 pilot 预期 800–1,200 条，**不需额外加深测序**

操作层面补充：六样本宿主残留 0.07–2.51%（冬季偏高），**去宿主不能省，且需按样本核查**。

五、局限

1. **季节与个体完全混淆**：冬季 F1/F2/F6（2016-01）、夏季 F3/F4/F5（2015-07），**六只不同个体、无任何配对**。本报告**不对季节做任何推断**；结果 3 说的是生理状态关联，不是季节导致。
2. **n=3，不做统计检验**，组间比较仅为描述。
3. **"摄食状态"是推断而非实测**：由 GC 与 16S 反推，缺摄食记录与血液指标直接支持。
4. **宿主预测覆盖 41.1%（83/202）**，未命中的 119 条不代表无宿主。覆盖率冬夏差异明显（65–70% vs 28–33%），因冬季病毒更接近已知噬菌体。
5. **202 条是下限估计**；数据来自 HiSeq 2500（2015–2016），跨研究比较需谨慎。

六、下一步

1. **挂靠血液项目做 20–30 样本 pilot**：不增加动物、不增加采血次数，仅加泄殖腔拭子 + 粪便，测序约 3.6–5.6 万（30 样本）。
2. **同一个体 3–4 个时间点**（入眠前 / 复苏后 / 活跃期 / 发病季），覆盖"健康 → 亚临床 → 临床 → 恢复"。
3. **元数据必须同步**：摄食/禁食状态、用药（尤其抗生素）、水温、圈舍、个体编号。缺这些，本报告踩过的坑会重演。
4. **低生物量对照**：提取空白、运输液空白、已知噬菌体 spike-in，血浆样本尤其需要。
5. 补做完整 iPHoP（需 ≥1 TB 磁盘）与裂解/溶源判定。

附图（英文图注）｜ **M1** 测序质量、去宿主、阈值断崖、功能构成｜ **M2** 群落分型、病毒组距离、16S 验证｜ **M3** 基因组的质量、产量、长度分布。脚本与结果表见 08_figures/、05_c_stage/。

数据来源 Tang K-Y, et al. *Metagenomics Reveals Seasonal Functional Adaptation of the Gut Microbiome to Host Feeding and Fasting in the Chinese Alligator.* Front Microbiol 2019;10:2409. **PMID 31708889**.

附图 / Supplementary figures

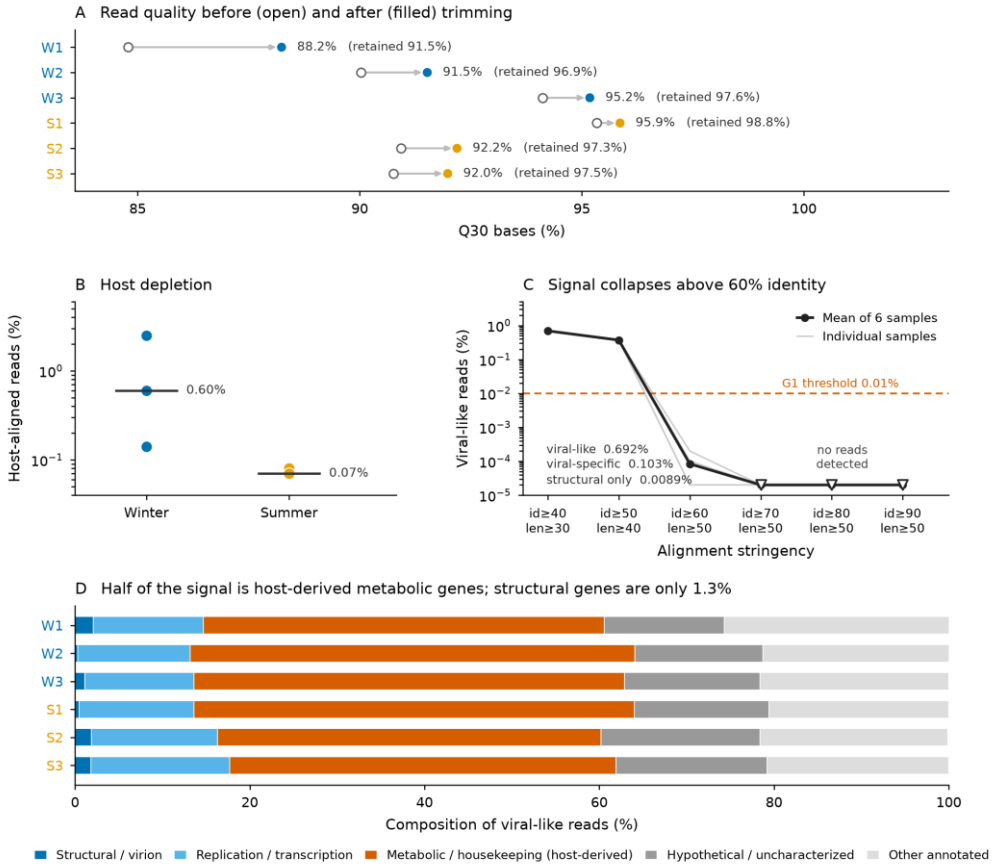


Figure M1 | Sequencing landscape and validation of viral signal. **(A)** Q30 bases before (open) and after (filled) trimming, with read retention. **(B)** Host-aligned fraction after host depletion (log scale); bars, group medians. **(C)** Viral-like read fraction versus alignment stringency (grey, individual samples; black, mean of six). The signal collapses above 60% identity, indicating that no reads derive from genomes closely related to known viruses; dashed line, 0.01% screening threshold. **(D)** Functional composition of viral-like reads: 47.4% map to metabolic/housekeeping enzymes carried by giant viruses, only 1.3% to virion structural genes. n = 3 per season; no statistical test applied.

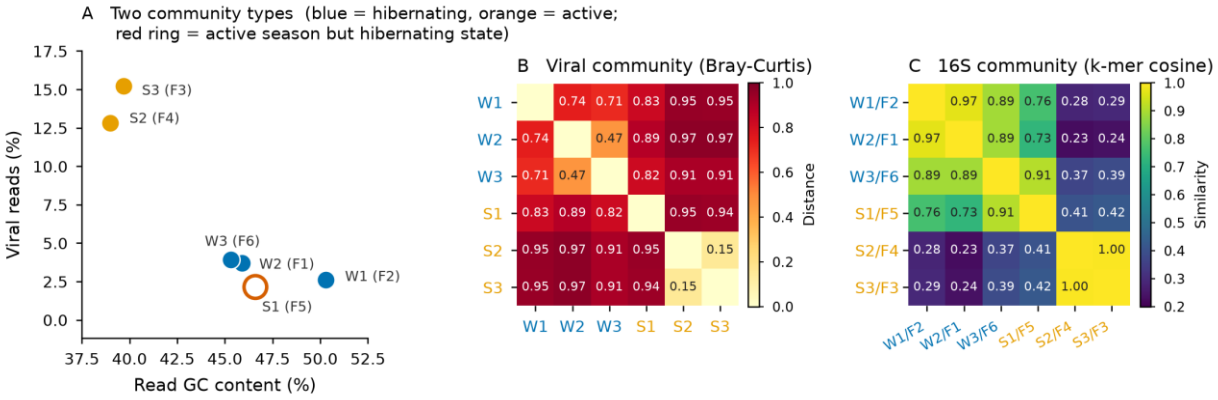


Figure M2 | Gut viral communities track host physiological state rather than calendar season. **(A)** Read GC content versus fraction of reads mapping to viral contigs. Blue, winter (hibernating); orange, summer (active). The red ring marks S1 (individual F5), collected in summer but harbouring a hibernating-type community. **(B)** Bray-Curtis dissimilarity between viral communities, computed on vOTU-level RPKM after mapping all samples to a unified reference of 9,980 vOTUs. **(C)** Bacterial 16S community similarity (15-mer cosine); A.F5 clusters with the winter animals (0.80 vs 0.41 to the summer group), independently confirming the state assignment derived from viral data. n = 3 per season.

附图（续）与附表 / Supplementary figures (cont.) and table

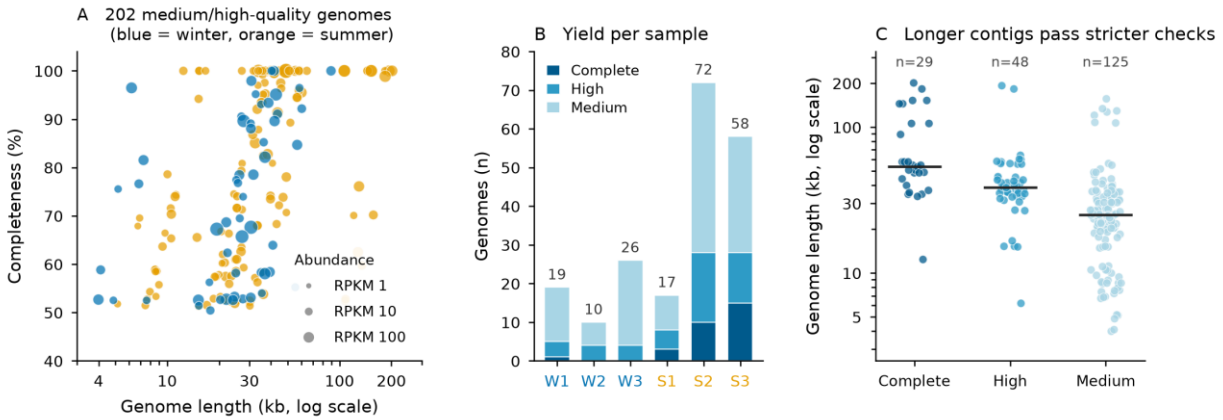


Figure M3 | Landscape of assembled viral genomes. **(A)** Length, completeness and abundance of the 202 medium- and high-quality viral genomes (point area scales with RPKM; blue, winter; orange, summer). **(B)** Genomes recovered per sample, coloured by CheckV quality tier. **(C)** Genome length by quality tier (log scale); bars, medians. Completeness calls are length-dependent, so the 202 genomes represent a lower bound on the true number of recoverable viral genomes.

附表 S1 ｜ 六样本关键指标 / Supplementary table S1. Sample-level metrics.

样本	采样期 / 个体	病毒 contigs	病毒占比	读段 GC	病毒 reads	中高质量基因组
W1	2016-01 / F2	549	1.87%	50.3%	2.62%	19
W2	2016-01 / F1	213	1.41%	45.9%	3.72%	10
W3	2016-01 / F6	926	4.92%	45.3%	3.91%	26
S1	2015-07 / F5	739	2.63%	46.6%	2.14%	17
S2	2015-07 / F4	5,074	13.34%	39.0%	12.81%	72
S3	2015-07 / F3	4,515	12.70%	39.7%	15.23%	58
合计	6 只个体	12,016	7.30%	—	—	202

病毒占比 = 病毒 contigs / 该样本 contigs 总数；中高质量 = CheckV Complete + High + Medium（完整性 ≥50%）；病毒 reads = 比对到统一 vOTU 参考的 reads 占比。W / S 前缀分别为 2016-01 与 2015-07 采样，六样本来自六只不同个体、无配对。

口径与可复现说明 / Definitions and reproducibility

- **病毒样（viral-like）：** DIAMOND blastx 比对 RVDB-prot v32（Unique, 783,103 蛋白），E ≤ 1e-5、一致性 ≥40%、比对长度 ≥30 aa；六样本均值 0.693%，仅作**上限**参考。
- **病毒特异（viral-specific）：** 仅计结构蛋白与复制/转录基因，均值 0.103%，为**本报告主指标**。
- **中高质量基因组：** CheckV 分级：Complete（完整性 ≥90%）、High（≥90% 且无污染）、Medium（≥50%）。
- **G1 闸门：** 判据为病毒 reads ≥0.01% 且 ≥10^4 条。按病毒特异口径达标（约超阈值 10 倍）；按仅结构蛋白口径（0.0089%）则不达标——故主指标的选择直接决定闸门结论。
- **数据与代码：** 原始数据 PRJNA539906 与 SRP315843（16S）；作图脚本见 08_figures/fig_m1–m3/code/，结果表见 05_c_stage/，服务器端流程见 workflow/server_run_c.sh。全部数值由真实计算生成，无占位数据。